

Víctimas de delitos sexuales en menores de edad en Bogotá D. C. 2012-2022

Estudio de caso 1 — Curso de Estadística Bayesiana, Universidad Nacional de Colombia

Lubin Abaunza

Email labaunza@unal.edu.co

1 Introducción

La base de datos disponible en este enlace contiene el total de víctimas según las entradas de noticias criminales por delito al Sistema Penal Oral Acusatorio en la Ley 906 de 2004 y Ley 1098 de 2006 desde hechos ocurridos en 2010.

A la fecha (01/03/23), la base suministrada por la Fiscalía General de la Nación contiene 3,651,193 registros y 25 campos. Toda la documentación se encuentra disponible en este enlace.

El objetivo de este caso de estudio es modelar el **conteo total de víctimas** en Bogotá D. C. en 2012-2022 para establecer si existen diferencias significativas por sexo respecto a delitos sexuales en menores de edad.

2 Tratamiento de datos

Para ajustar los modelos propuestos en 2022 (similarmemente para los demás años), se consideran los individuos tales que:

- El proceso sí corresponde a un hecho.
- El estado de la noticia criminal es activo.
- El año en que se denunció el hecho es 2022.
- El año en que entró a la Fiscalía la noticia criminal es 2022.
- El año en que presuntamente ocurrió el hecho es 2022.
- El departamento es Bogotá D. C..
- La agrupación de los delitos del código penal es delitos sexuales.
- El país de nacimiento de la víctima es Colombia.
- El país en donde presuntamente ocurrieron los hechos que conoció la Fiscalía es Colombia.
- La agrupación de edad a la que pertenece la víctima es primera infancia, infancia, pre-adolescente, o adolescente.

La base de datos filtrada de esta manera sin tener en cuenta ningún otro aspecto de los demás campos contiene 394 registros, a saber, 116 hombres, 270 mujeres, 8 sin información. Finalmente, se remueven los registros sin información de sexo, y acto seguido, también se remueven los *outliers* extremos asociados con el conteo total de víctimas. Así, se obtienen conteos asociados con 115 hombres y 237 mujeres.

Nota: una observación de una variable de interés se denomina *outlier* extremo si la observación es bien sea inferior a $q_1 - 3.0RI$ o superior a $q_3 + 3.0RI$, donde q_1 y q_3 son el percentil 25 y 75 de la variable, respectivamente, y $RI = q_3 - q_1$ es el rango intercuartílico.

3 Análisis Bayesiano en Bogotá D. C. en 2022

Sea $\mathbf{y}_k = (y_{k,1}, \dots, y_{k,n_k})$ el vector de observaciones correspondientes al conteo total de víctimas asociados con la población k , con $k = 1$ (hombres) y $k = 2$ (mujeres). Se consideran modelos Gamma-Poisson de la

forma

$$y_{k,i} \mid \theta_k \stackrel{\text{iid}}{\sim} \text{Poisson}(\theta_k), \quad i = 1, \dots, n_k, \\ \theta_k \sim \text{Gamma}(a_k, b_k)$$

donde a_k y b_k son hiperparámetros, para $k = 1, 2$.

3.1 Ajuste del modelo

Una aplicación directa del teorema de Bayes se demuestra que en este caso la distribución posterior de θ_k está dada por

$$\theta_k \sim \text{Gamma}(a_k + s_k, b_k + n_k)$$

donde $s_k = \sum_{i=1}^{n_k} y_{k,i}$ es la suma de los conteos asociados con la población k y n_k es el tamaño de la muestra correspondiente, con $k = 1$ (hombres) y $k = 2$ (mujeres).

Específicamente, utilizando distribuciones previas no informativas definidas por $a_k = b_k = 0.01$ (las distribuciones resultan aproximadamente planas en las regiones de alta densidad de los parámetros), se tiene que

$$\theta_1 \sim \text{Gamma}(208.01, 115.01) \quad \text{y} \quad \theta_2 \sim \text{Gamma}(539.01, 237.01).$$

Estas distribuciones se presentan de manera simultanea junto con la distribución previa en la siguiente Figura.




Figure 1: Distribución posterior de hombres y mujeres junto con la distribución previa.

3.2 Comparación de las tasas promedio de victimización

Con el fin de comparar las tasas promedio de victimización, se investiga el parámetro $\eta = (\theta_2 - \theta_1)/\theta_1$ correspondiente al cambio proporcional en las tasas promedio de victimas de delitos sexuales en menores de edad entre mujeres y hombres respecto a los hombres en Bogotá D. C. en 2022.

Así, usando métodos de Monte Carlo, se generan $B = 5000$ muestras independientes idénticamente distribuidas de la distribución posterior de cada grupo,

$$\theta_1^{(1)}, \dots, \theta_1^{(B)} \sim \text{Gamma}(208.01, 115.01) \quad \text{y} \quad \theta_2^{(1)}, \dots, \theta_2^{(B)} \sim \text{Gamma}(539.01, 237.01),$$

y se calcula

$$\eta^{(b)} = \frac{\theta_2^{(b)} - \theta_1^{(b)}}{\theta_1^{(b)}}, \quad b = 1, \dots, B,$$

con el fin de aproximar cualquier cantidad asociada con la distribución posterior de η . A continuación se presenta la distribución posterior de η , junto con la media, el coeficiente de variación, y un intervalo de credibilidad al 95%.

Se estima que la tasa de victimización de las mujeres es, en promedio, 26 puntos superior a la de los hombres, tomando como referencia la tasa de los hombres. Además, con una probabilidad del 95%, esta diferencia relativa se encuentra entre 7 y 47 puntos. Estos resultados evidencian que, bajo el modelo propuesto, la tasa promedio de víctimas en mujeres fue significativamente mayor que la observada en hombres en Bogotá D. C. durante 2022.

Table 1: Distribución posterior de η .

	Media	CV	2.5%	97.5%
η	0.262	0.395	0.07	0.474

3.3 Análisis de sensibilidad

Ahora se lleva a cabo un análisis de sensibilidad a las inferencias por medio de la especificación de diferentes distribuciones previas. Para ello, se consideran los siguientes estados de información externos al conjunto de datos:

- Distr. Previa 1: $a_k = b_k = 0.01$, para $k = 1, 2$.
- Distr. Previa 2: $a_k = b_k = 0.10$, para $k = 1, 2$.
- Distr. Previa 3: $a_k = b_k = 1.00$, para $k = 1, 2$.
- Distr. Previa 4: $a_k = 1.00$ y $b_k = 1/2$, para $k = 1, 2$.
- Distr. Previa 5: $a_k = 1.00$ y $b_k = 1/3$, para $k = 1, 2$.
- Distr. Previa 6: $a_k = 1.00$ y $b_k = 1/4$, para $k = 1, 2$.

Siguiendo el mismo protocolo de la sección anterior, en cada caso se obtiene la distribución posterior de η , junto con la media, el coeficiente de variación, y un intervalo de credibilidad al 95%. Los resultados correspondientes se presentan a continuación.

Las inferencias sobre la tasa de cambio que compara la victimización entre mujeres y hombres, tomando como referencia a los hombres, resultan robustas frente a la información externa incorporada al modelo. Esto se debe a que la distribución posterior, así como sus correspondientes medidas resumen, no presenta variaciones sustanciales entre las distintas distribuciones previas consideradas.




Figure 2: Distribución posterior de η .

Table 2: Distribución posterior de η bajo diferentes distribuciones previas.

	Media Prev. θ_k	CV Prev. θ_k	Media η	CV η	2.5% η	97.5% η
Previa 1	1	10.000	0.262	0.395	0.070	0.474
Previa 2	1	3.162	0.264	0.400	0.074	0.492
Previa 3	1	1.000	0.264	0.390	0.074	0.480
Previa 4	2	1.000	0.262	0.394	0.079	0.477
Previa 5	3	1.000	0.263	0.387	0.073	0.477
Previa 6	4	1.000	0.260	0.395	0.070	0.475




Figure 3: Distribución posterior de η bajo diferentes distribuciones previas.

3.4 Bondad de ajuste

Ahora, se evalúa la bondad de ajuste del modelo propuesto en cada población utilizando la distribución predictiva posterior de la media y la desviación estándar (estadísticos de prueba).

Nuevamente, usando métodos de Monte Carlo, para cada muestra $\theta_k^{(1)}, \dots, \theta_k^{(B)}$ de la distribución posterior de θ_k de cada grupo, para $k = 1, 2$, se genera un nuevo conjunto de n_k observaciones $\tilde{\mathbf{y}}_k^{(b)} = (\tilde{y}_{k,1}^{(b)}, \dots, \tilde{y}_{k,n_k}^{(b)})$ condicional en el valor de $\theta_k^{(b)}$, esto es,

$$\tilde{y}_{k,1}^{(b)}, \dots, \tilde{y}_{k,n_k}^{(b)} \mid \theta_k^{(b)} \sim \text{Poisson}(\theta_k^{(b)}), \quad b = 1, \dots, B.$$

Luego, para cada nuevo conjunto de datos $\tilde{\mathbf{y}}_k^{(b)}$ se calcula tanto la media como la desviación estándar, lo que produce una secuencia de B muestras aleatorias de la distribución predictiva posterior de cada uno de estos estadísticos.

Finalmente, se dice que un modelo es un “buen modelo” si el valor del estadístico usando los datos observados es un valor típico de la distribución predictiva posterior correspondiente. Esta característica se puede cuantificar por medio del valor p predictivo posterior (ppp). Los resultados correspondientes se presentan a continuación.

El modelo propuesto permite caracterizar adecuadamente la media del conteo de víctimas tanto en hombres como en mujeres ($ppp = 0.477$ y $ppp = 0.482$, respectivamente). Por otra parte, aunque el modelo describe de manera satisfactoria la variabilidad del conteo de víctimas en hombres ($ppp = 0.081$), existe evidencia importante de que subestima dicha variabilidad en el caso de las mujeres ($ppp = 0.000$).

Table 3: Valores p predictivos posteriores de los estadísticos de prueba.

	Media	Desv. Estándar
Hombres	0.477	0.081
Mujeres	0.482	0.000




Figure 4: Distribución predictiva posterior conjunta de los estadísticos de prueba junto con el valor observado correspondiente.

4 Análisis frecuentista en Bogotá D. C. en 2022

Aquí, nuevamente se hace inferencia sobre el parámetro $\eta = (\theta_2 - \theta_1)/\theta_1$ correspondiente al cambio proporcional en las tasas promedio de victimas de delitos sexuales en menores de edad entre mujeres y hombres respecto a los hombres en Bogotá D. C. en 2022, pero esta vez, bajo el paradigma frecuentista usando *Bootstrap* paramétrico.

4.1 Ajuste del modelo

Se asume que los datos en cada grupo surgen de acuerdo a un modelo Poisson con parámetro θ_k , esto es,

$$y_{k,i} \mid \theta_k \sim \text{Poisson}(\theta_k), \quad i = 1, \dots, n_k, \quad k = 1, 2.$$

Para hacer inferencia frecuentista usando esta familia paramétrica mediante técnicas de remuestreo, se sigue el siguiente algoritmo:

1. Estimar θ_k , para $k = 1, 2$, usando máxima verosimilitud. En este caso, el estimador máximo verosímil de θ_k es $\hat{\theta}_{\text{mle } k} = \bar{y}_k = \frac{1}{n_k} \sum_{i=1}^{n_k} y_{k,i}$. Específicamente, se tiene que $\hat{\theta}_{\text{mle } 1} = 1.809$ y $\hat{\theta}_{\text{mle } 2} = 2.274$.
2. Generar un nuevo conjunto de n_k observaciones $\tilde{y}_{k,1}, \dots, \tilde{y}_{k,n_k}$ a partir del modelo supuesto usando el valor de $\hat{\theta}_{\text{mle } k}$, es decir,

$$\tilde{y}_{k,1}, \dots, \tilde{y}_{k,n_k} \sim \text{Poisson}(\hat{\theta}_{\text{mle } k}), \quad k = 1, 2.$$

3. Estimar θ_k a partir de la remuestra $\tilde{y}_{k,1}, \dots, \tilde{y}_{k,n_k}$, para $k = 1, 2$, mediante $\tilde{\theta}_k = \frac{1}{n_k} \sum_{i=1}^{n_k} \tilde{y}_{k,i}$, y calcular

$$\tilde{\eta} = \frac{\tilde{\theta}_2 - \tilde{\theta}_1}{\tilde{\theta}_1}.$$

4. Repetir los pasos 2. y 3. $B = 5000$ veces.
5. Considerar la distribución empírica de $\tilde{\eta}_1, \dots, \tilde{\eta}_B$ como una aproximación a la distribución del estimador máximo verosímil de η dado por $\hat{\eta}_{\text{mle}} = (\hat{\theta}_{\text{mle } 2} - \hat{\theta}_{\text{mle } 1})/\hat{\theta}_{\text{mle } 1}$.

A continuación se presenta la aproximación a la distribución de $\hat{\eta}_{\text{mle}}$, junto con la media, el coeficiente de variación, y un intervalo de credibilidad al 95%. Como punto de referencia, también se presenta la inferencia Bayesiana de la Sección 3.2.

Ambos enfoques producen inferencias prácticamente idénticas sobre la tasa de cambio que compara la victimización entre mujeres y hombres, tomando como referencia a los hombres. Este resultado no es inesperado, dado que la distribución previa empleada en el análisis Bayesiano es difusa y, además, los tamaños de muestra para hombres y mujeres son suficientemente grandes como para dominar las inferencias en un espacio paramétrico de baja dimensión.

Table 4: Distribución posterior de η .

	Media	CV	2.5%	97.5%
Inferencia Bayesiana	0.262	0.395	0.070	0.474
Inferencia Frecuentista	0.263	0.397	0.068	0.487

4.2 Simulación: tasas de cobertura de los intervalos

Con el fin de evaluar y comparar la idoneidad de los intervalos bajo ambos paradigmas, se simulan 100000 muestras aleatorias de poblaciones Poisson bajo los siguientes escenarios:




Figure 5: Distribución posterior de η .

- Escenario 1: $n_1 = 10$, $n_2 = 10$, $\theta_1 = \bar{y}_1$, y $\theta_2 = \bar{y}_2$.
- Escenario 2: $n_1 = 20$, $n_2 = 20$, $\theta_1 = \bar{y}_1$, y $\theta_2 = \bar{y}_2$.
- Escenario 3: $n_1 = 50$, $n_2 = 50$, $\theta_1 = \bar{y}_1$, y $\theta_2 = \bar{y}_2$.
- Escenario 4: $n_1 = 100$, $n_2 = 100$, $\theta_1 = \bar{y}_1$, y $\theta_2 = \bar{y}_2$.

donde $\bar{y}_k = \frac{1}{n_k} \sum_{i=1}^{n_k} y_{k,i}$ es la media muestral observada de la población k , para $k = 1, 2$, esto es, $\bar{y}_1 = 1.809$ y $\bar{y}_2 = 2.274$. En cada escenario el valor verdadero de η es $\eta = (\bar{y}_2 - \bar{y}_1)/\bar{y}_1 = 0.257$.

Usando cada muestra, se ajusta el modelo de manera tanto Bayesiana (usando la distribución previa $a_k = b_k = 0.01$) como frecuentista (usando *Bootstrap* paramétrico), y en cada caso se calcula la proporción de veces que el intervalo de credibilidad/confianza al 95% contiene el valor verdadero de η .

Nuevamente, ambos enfoques producen tasas de cobertura para η prácticamente idénticas y cercanas al 95%, tal como se esperaba. Estos resultados son alentadores, ya que en ambos casos la cobertura empírica coincide de manera adecuada con la cobertura nominal.

Table 5: Tasas de cobertura de los intervalos de credibilidad/confianza para η .

	Inferencia Bayesiana	Inferencia Frecuentista
$n = 10$	0.936	0.939
$n = 20$	0.948	0.946
$n = 50$	0.948	0.949
$n = 100$	0.954	0.955

5 Análisis Bayesiano y frecuentista en Bogotá D. C. en 2012-2022

Finalmente, siguiendo el mismo protocolo de las secciones 3.2 y 4.1, se ajusta el modelo de manera tanto Bayesiana (usando la distribución previa $a_k = b_k = 0.01$) como frecuentista (usando *Bootstrap* paramétrico) para cada año de 2012 a 2022 (inclusive), y se obtiene tanto una estimación puntual como intervalos de credibilidad/confianza al 95% y 99% para $\eta = (\theta_2 - \theta_1)/\theta_1$, es decir, el cambio proporcional en las tasas

promedio de víctimas de delitos sexuales en menores de edad entre mujeres y hombres respecto a los hombres en Bogotá D. C.. En la siguiente Figura se presentan los resultados.

Al igual que en los análisis anteriores, las inferencias obtenidas bajo ambos paradigmas son muy similares. En la mayoría de los años, la estimación puntual de la tasa de cambio que compara la victimización entre mujeres y hombres, tomando como referencia a los hombres, es superior a cero —con excepción de 2013—, lo que sugiere una mayor victimización en mujeres durante el periodo 2012–2022. Sin embargo, dichas diferencias solo resultan estadísticamente significativas al 95% en 2016, 2018, 2019 y 2022. Las mayores diferencias se observan en 2016, mientras que las menores se presentan en 2013. Finalmente, la amplitud de los intervalos evidencia una mayor incertidumbre en la estimación de la tasa de cambio entre 2012 y 2016, la cual disminuye de manera considerable entre 2017 y 2022.




Figure 6: Estimación puntual e intervalos de credibilidad/confianza al 95% (línea gruesa) y al 99% (línea delgada) para η en 2012-2022.